UNIVERSITÉ PARIS CITÉ

Master 2: Ingénierie Statistique et Informatique de la Finance, de l'Assurance et du Risque (ISIFAR)

Apprentissage statistique

Modélisation et prédiction du défaut de paiement des titulaires de cartes de crédit

Professeur :
Aurélie Fischer

Étudiant :
NGUYEN Chung Anh

2025–2026

Contents

1 Introduction 1
2 Analyse exploratoire des données 1
  2.1 Description du jeu de données 1
  2.2 Distribution des données 3
  2.3 Structure des données et nettoyage 3
  2.4 Variables catégorielles 3
  2.5 Corrélation 5
3 Prétraitement des données 6
4 Évaluation du modèle 6
  4.1 Validation croisée k-fold 6
  4.2 Performance Evaluation Metrics 7
  4.3 ROC Curve and AUC Metric 9
5 Modèles de classification 10
  5.1 Arbre de décision et Random Forest 10
6 Résultats 12
  6.1 Decision Tree 12
  6.2 Random forest 13
  6.3 Overall overview 13
7 Conclusion 14

Abstract

Cette étude mobilise plusieurs algorithmes d'apprentissage supervisé afin d'identifier les facteurs déterminants de la probabilité de défaut de paiement sur cartes de crédit. Elle met particulièrement l'accent sur les fondements mathématiques et les méthodes employées. Les défauts de paiement apparaissent notamment lorsque les titulaires de cartes se trouvent en situation de difficulté financière sévère. Dans une logique d'expansion commerciale, les banques taïwanaises ont accordé un volume excessif de crédits et de cartes à des demandeurs insuffisamment qualifiés. Parallèlement, de nombreux utilisateurs ont eu recours à une utilisation excessive de leur carte, indépendamment de leur capacité réelle de remboursement, accumulant ainsi des niveaux élevés de dettes.

L'objectif de cette étude est de concevoir un modèle automatisé capable d'identifier les facteurs clés du défaut de paiement et de prédire ce risque à partir d'informations clients et d'historiques transactionnels. Les concepts fondamentaux de l'apprentissage supervisé sont présentés, suivis d'une description détaillée des techniques statistiques et des algorithmes utilisés. Les modèles reposent principalement sur des algorithmes d'arbres de décision et de forêts aléatoires.

1 Introduction

Depuis 1990, le gouvernement taïwanais a autorisé la création de nouvelles banques. Afin d'accroître leur part de marché, ces établissements ont distribué un volume excessif de liquidités et de cartes de crédit à des demandeurs peu qualifiés. Parallèlement, la plupart des titulaires de cartes, indépendamment de leur capacité réelle de remboursement, ont abusé de leur carte pour la consommation, accumulant ainsi d'importantes dettes. Un défaut survient lorsqu'un détenteur de carte de crédit n'est plus en mesure de respecter son obligation légale de remboursement. Cette situation a fortement ébranlé la confiance dans le crédit à la consommation et constitue un défi majeur tant pour les banques que pour les emprunteurs [1].

Dans un système financier développé, la gestion de crise intervient en aval, tandis que la prédiction du risque se situe en amont. L'objectif principal de la prévision du risque est d'exploiter des informations financières telles que les états financiers, les transactions des clients ou encore leurs historiques de remboursement, afin de prédire la performance d'un client ou son risque de crédit et de réduire ainsi les pertes potentielles et l'incertitude.

Dans ce projet, l'objectif est de prédire de manière fiable quels clients présentent un risque de défaut. Une telle anticipation permettrait à la banque de prévenir les pertes en proposant, par exemple, des solutions alternatives (telles que des reports d'échéance ou des consolidations de dettes). Pour cela, nous construisons un modèle automatisé fondé sur les informations clients et leurs transactions historiques, capable d'identifier les facteurs clés et de prédire le défaut de paiement sur carte de crédit.

2 Analyse exploratoire des données

2.1 Description du jeu de données

Le jeu de données *Default of Credit Card Clients* contient 30 000 observations décrivant la situation des titulaires de cartes de crédit à Taïwan, collectées entre avril 2005 et septembre 2005. La variable cible est binaire : *default payment next month*, indiquant si un client fera défaut le mois suivant (Oui = 1, Non = 0).

Pour chaque observation (c'est-à-dire chaque client), nous disposons d'informations démographiques, de données de crédit, de l'historique des paiements ainsi que des relevés mensuels. Plus précisément, la liste complète des 23 prédicteurs est donnée ci-dessous [1].

- **Informations personnelles du client :**
  1. **LIMIT_BAL** : Montant total du crédit accordé (en dollars taïwanais), incluant le crédit individuel et celui de la famille (cartes supplémentaires).
  2. **SEX** : 1 = homme ; 2 = femme.
  3. **EDUCATION** : 1 = cycle supérieur ; 2 = université ; 3 = lycée ; 4 = autres.
  4. **MARRIAGE** : Statut marital, 1 = marié ; 2 = célibataire ; 3 = autres.
  5. **AGE** : Âge en années.
- **Historique des paiements de avril à septembre 2005**, indiquant le retard de paiement du mois correspondant :

6. **PAY_0** : Statut de remboursement en septembre 2005.
7. **PAY_2** : Statut de remboursement en août 2005.
8. **PAY_3** : Statut de remboursement en juillet 2005.
9. **PAY_4** : Statut de remboursement en juin 2005.
10. **PAY_5** : Statut de remboursement en mai 2005.
11. **PAY_6** : Statut de remboursement en avril 2005.

L'échelle de mesure pour le statut de remboursement est la suivante : `-1 = paiement effectué à temps ; 1 = retard d'un mois ; 2 = retard de deux mois ; ... ; 8 = retard de huit mois ; 9 = retard de neuf mois ou plus.`

- **Montants des relevés mensuels** (en dollars taïwanais), c'est-à-dire les factures envoyées aux titulaires de carte chaque mois :

12. **BILL_AMT1** : Montant du relevé de septembre 2005.
13. **BILL_AMT2** : Montant du relevé d'août 2005.
14. **BILL_AMT3** : Montant du relevé de juillet 2005.
15. **BILL_AMT4** : Montant du relevé de juin 2005.
16. **BILL_AMT5** : Montant du relevé de mai 2005.
17. **BILL_AMT6** : Montant du relevé d'avril 2005.

- **Montants des paiements précédents** (en dollars taïwanais) :

18. **PAY_AMT1** : Montant du paiement effectué en septembre 2005.
19. **PAY_AMT2** : Montant du paiement effectué en août 2005.
20. **PAY_AMT3** : Montant du paiement effectué en juillet 2005.
21. **PAY_AMT4** : Montant du paiement effectué en juin 2005.
22. **PAY_AMT5** : Montant du paiement effectué en mai 2005.
23. **PAY_AMT6** : Montant du paiement effectué en avril 2005.

La Figure 1 illustre un aperçu du jeu de données. La variable cible *default.payment.next.month* a été renommée `DEFAULT` afin de simplifier les notations, tandis que la variable *PAY_0* a été renommée `PAY_1`.

ID	LIMIT_BAL	SEX	EDUCATION	MARRIAGE	AGE	PAY_0	PAY_2	PAY_3	PAY_4	PAY_5	PAY_6	BILL_AMT1	BILL_AMT2	BILL_AMT3	BILL_AMT4	BILL_AMT5
<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	20000	2	2	1	24	2	2	-1	-1	-2	-2	3913	3102	689	0	0
2	120000	2	2	2	26	-1	2	0	0	0	2	2682	1725	2682	3272	3455
3	90000	2	2	2	34	0	0	0	0	0	0	29239	14027	13559	14331	14948
4	50000	2	2	1	37	0	0	0	0	0	0	46990	48233	49291	28314	28959
5	50000	1	2	1	57	-1	0	-1	0	0	0	8617	5670	35835	20940	19146
6	50000	1	1	2	37	0	0	0	0	0	0	64400	57069	57608	19394	19619

Figure 1: Original dataset from UCI machine learning repository through R

2.2 Distribution des données

La Figure 2 présente la distribution de la variable cible *default payment next month*. On observe clairement un déséquilibre marqué en faveur de la classe 0 (absence de défaut), qui représente environ 78 % de l'ensemble du jeu de données. Si ce déséquilibre n'est pas traité, les modèles de classification auront tendance à se concentrer sur la classe majoritaire, au détriment de la classe minoritaire, ce qui dégrade la qualité de la prédiction du défaut [3].

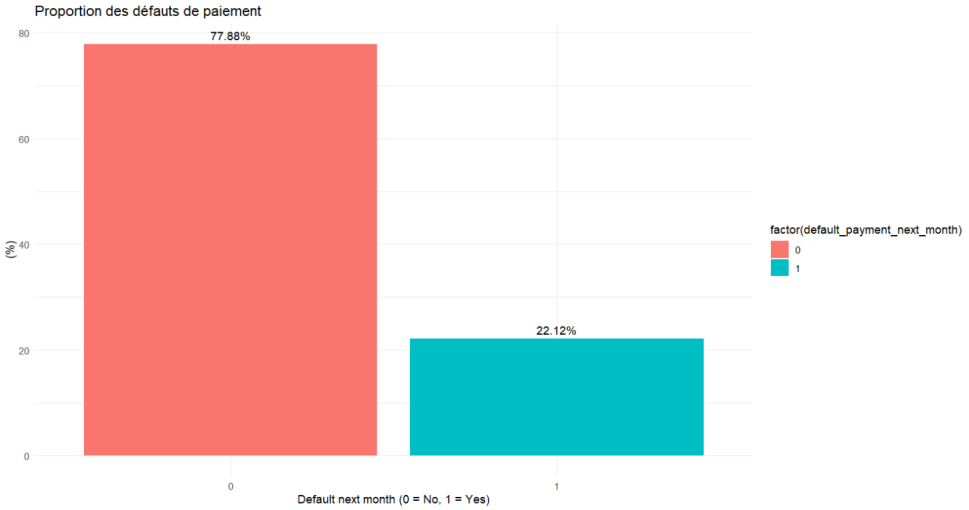

Figure 2: Countplot of default payment next month

2.3 Structure des données et nettoyage

En examinant les valeurs présentes dans les différents attributs, plusieurs corrections s'avèrent nécessaires :

- L'attribut **MARRIAGE** devrait uniquement prendre les valeurs 1, 2 ou 3 ; cependant, certaines observations présentent la valeur 0.
- L'attribut **EDUCATION** devrait être codé uniquement par les valeurs 1, 2, 3 ou 4 ; néanmoins, le jeu de données contient des valeurs 0, 5 et 6.
- Les attributs **PAY_N** devraient appartenir à l'ensemble {-1, 1, 2, 3, 4, 5, 6, 7, 8, 9}, mais certaines observations contiennent les valeurs -2 et 0.

Dans les deux premiers cas, comme il existe déjà une catégorie correspondant à *Autres* (la valeur 3 pour **MARRIAGE** et 4 pour **EDUCATION**), toutes les valeurs inconnues ont été réaffectées à cette catégorie.

Dans le troisième cas, afin d'utiliser les variables **PAY_N** comme attributs numériques (et non catégoriels), les valeurs -2 et -1 ont été remappées à 0. Ainsi, la variable **PAY_N** représente désormais le nombre de mois de retard de paiement.

2.4 Variables catégorielles

En ce qui concerne les variables catégorielles **SEX**, **EDUCATION** et **MARRIAGE**, illustrées dans la Figure 3 et dans le Tableau 2, on observe qu'il y a nettement plus de

femmes que d'hommes dans le jeu de données. Par ailleurs, les hommes présentent une probabilité légèrement plus élevée de faire défaut que les femmes (0,24 % contre 0,21 %). Toutefois, de manière générale, les proportions de *défaillants* et de *non-défaillants* au sein de chaque catégorie restent cohérentes avec celles observées dans les deux autres variables.

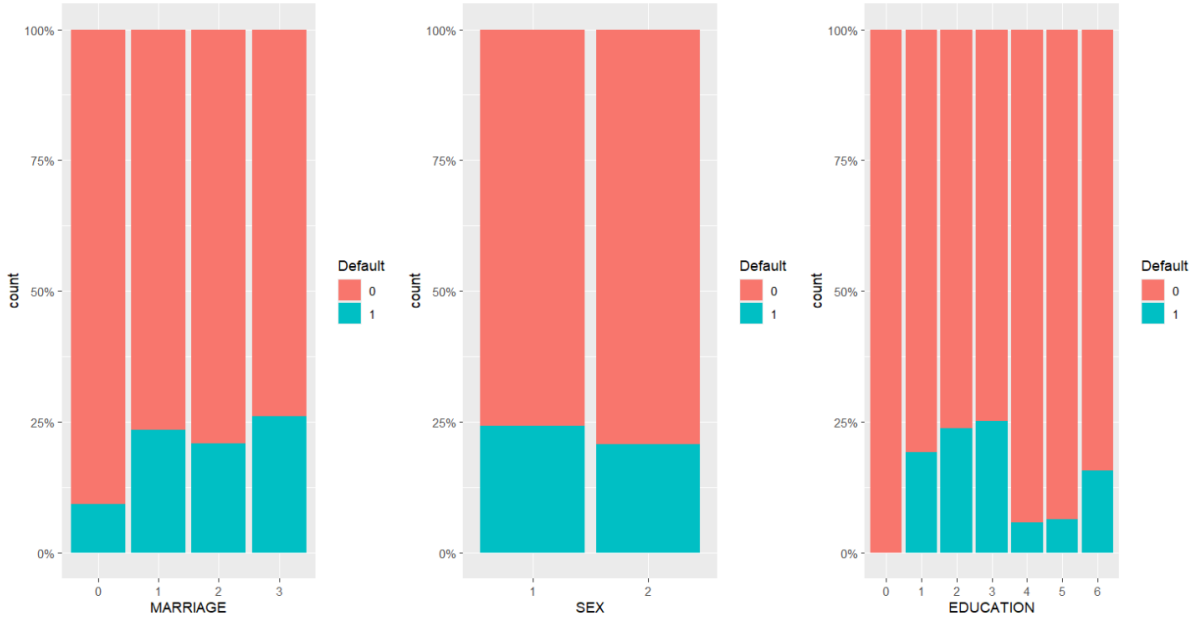

Figure 3: Countplot of SEX, EDUCATION and MARRIAGE grouped by DEFAULT class

Nous devons également analyser la variable relative au statut de paiement **PAY_N**. Les boxplots présentés dans la Figure 4 sont particulièrement informatifs. Ils montrent que les clients dont le retard de paiement est d'un mois ou moins présentent un taux de défaut nettement plus faible. En d'autres termes, le statut de remboursement du mois de septembre, **PAY_1**, possède un pouvoir discriminant plus élevé que les statuts de paiement des autres mois.

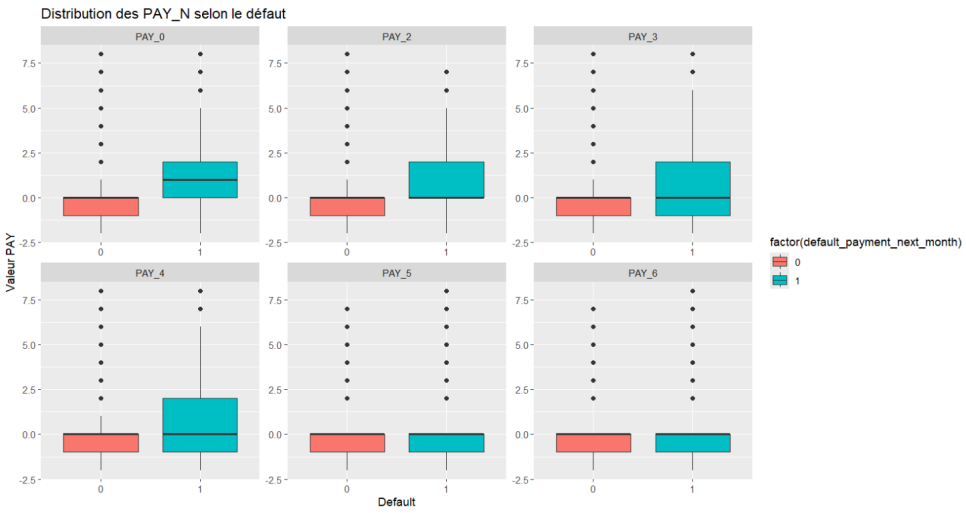

Figure 4: Boxplots of PAY N grouped by DEFAULT class

2.5 Corrélation

La corrélation désigne le degré selon lequel deux variables aléatoires évoluent conjointement. Intuitivement, lorsque deux variables évoluent dans le même sens, on parle de corrélation positive ; à l'inverse, lorsqu'elles évoluent en sens opposé, on parle de corrélation négative. Le coefficient de corrélation de Pearson (ρ) est l'une des mesures les plus couramment utilisées pour quantifier la dépendance linéaire entre deux variables.

$$\rho(X,Y) = \frac{\mathrm{Cov}(X,Y)}{\sigma_X \sigma_Y} = \frac{\mathbb{E}[(X-\mu_X)(Y-\mu_Y)]}{\sigma_X \sigma_Y} \tag{1}$$

La valeur du coefficient de Pearson varie dans l'intervalle $[-1, 1]$:

- $+1$ indique une corrélation parfaitement positive ;
- 0 indique l'absence de corrélation linéaire (les variables sont statistiquement indépendantes, même si l'inverse n'est pas nécessairement vrai en présence de relations non linéaires) ;
- -1 indique une corrélation parfaitement négative.

Des valeurs élevées de la corrélation entre une variable explicative et la variable cible peuvent indiquer une redondance informationnelle, ce qui peut justifier l'élimination de certaines variables. La Figure 7 présente une représentation graphique de la corrélation de Pearson sous forme de *heatmap*, où chaque cellule (i, j) indique la corrélation entre les variables aléatoires X_i et X_j.

Comme on peut l'observer sur la Figure 5, des corrélations « internes » apparaissent au sein de certains groupes de variables, notamment les variables **BILL_AMT** et **PAY_N**. En revanche, aucune variable ne présente une corrélation forte avec la variable cible. Plus précisément, 15 variables ont une corrélation absolue inférieure à 0.1, et aucune des autres ne dépasse une corrélation de 0.29.

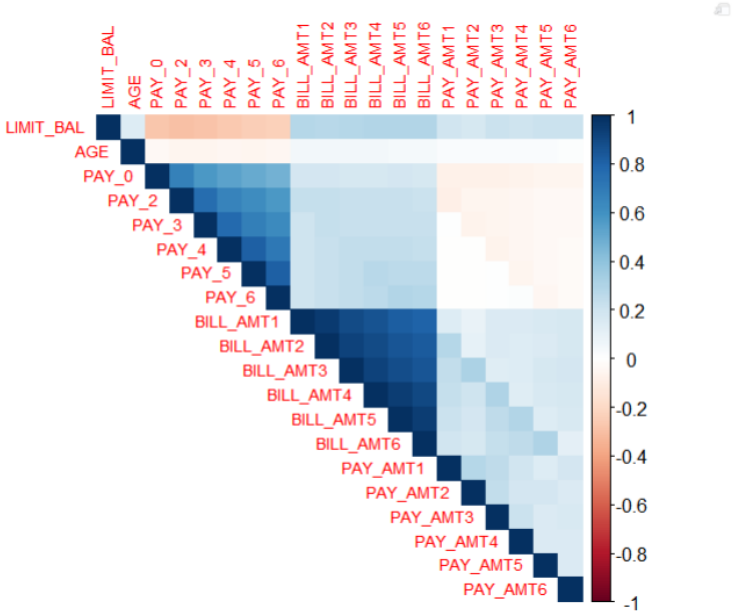

Figure 5: Heatmap correlation

3 Prétraitement des données

Une pratique courante pour évaluer les performances d'un algorithme de classification consiste à diviser le jeu de données en deux parties : un ensemble d'entraînement et un ensemble de test. L'ensemble d'entraînement est utilisé pour ajuster le modèle d'apprentissage automatique, tandis que l'ensemble de test sert à évaluer les performances du modèle entraîné.

Dans notre cas, étant donné que le jeu de données comporte un nombre suffisant d'observations, 75 % des données initiales sont utilisées pour l'entraînement et les 25 % restantes pour le test, tout en préservant la distribution initiale de la variable cible.

4 Évaluation du modèle

L'une des étapes essentielles dans la construction d'un modèle d'apprentissage automatique est d'estimer ses performances sur des données qu'il n'a jamais vues auparavant. Pour cette raison, comme indiqué dans la Section 3, le jeu de données initial a été divisé en un ensemble d'entraînement et un ensemble de test. Le premier est utilisé pour entraîner le modèle, tandis que le second permet d'évaluer sa capacité de généralisation. Cette méthode est communément appelée *méthode holdout*.

4.1 Validation croisée k-fold

Plutôt que d'utiliser uniquement la méthode holdout, une technique plus robuste pour l'ajustement des modèles est la validation croisée *k-fold*. Celle-ci consiste à répéter la méthode holdout k fois sur k sous-ensembles distincts du jeu de données d'entraînement.

En pratique, l'ensemble d'entraînement est divisé aléatoirement, sans remise, en k parties (*folds*). À chaque itération, $k - 1$ folds sont utilisés pour l'entraînement du modèle, et le fold restant est utilisé pour évaluer ses performances. Nous calculons ensuite la performance moyenne sur les k folds afin d'obtenir une estimation moins sensible à la manière dont les données ont été sous-partitionnées, comparée à la méthode holdout classique.

Une fois des hyperparamètres satisfaisants déterminés, le modèle est réentraîné sur l'intégralité de l'ensemble d'entraînement, puis évalué une dernière fois sur l'ensemble de test indépendant. L'idée sous-jacente est que fournir davantage d'exemples d'apprentissage conduit généralement à un modèle plus précis et plus robuste.

Figure 6: K-fold cross validation. [4]

Puisque la validation croisée *k-fold* est une technique de rééchantillonnage sans remise, son principal avantage est que chaque observation de l'ensemble d'entraînement est utilisée exactement une fois comme donnée de validation. Cela permet d'obtenir une estimation de la performance du modèle avec une variance plus faible que celle obtenue via la méthode holdout.

La valeur la plus couramment utilisée pour k dans la validation croisée est $k = 10$ [**?**]. Cependant, étant donné la taille importante du jeu de données, ce choix impliquerait un coût computationnel trop élevé. Nous adoptons donc une valeur plus faible, à savoir $k = 5$, tout en bénéficiant des avantages de la méthode *k-fold*.

4.2 Performance Evaluation Metrics

Les métriques d'évaluation en classification comparent la classe prédite par un modèle à la classe réelle des observations. Un outil central pour cela est la **matrice de confusion**, où l'élément (j, k) indique le nombre de fois où la classe réelle est j alors que la classe prédite est k.

Dans le cas binaire — comme dans notre étude — la matrice de confusion devient plus simple à construire et à interpréter. Si les deux classes sont *Positive* et *Negative*, la matrice correspondante est donnée dans le Tableau 1.

Table 1: Binary classification confusion matrix

	Actual Class	
Predicted Class	Positive	Negative
Positive	TP	FP
Negative	FN	TN

La terminologie associée aux différentes composantes de la matrice de confusion est la suivante :

- **True Positive (TP):** positive examples correctly predicted.
- **False Negative (FN):** positive examples incorrectly predicted as negative.

- **False Positive (FP):** negative examples incorrectly predicted as positive.
- **True Negative (TN):** negative examples correctly predicted.

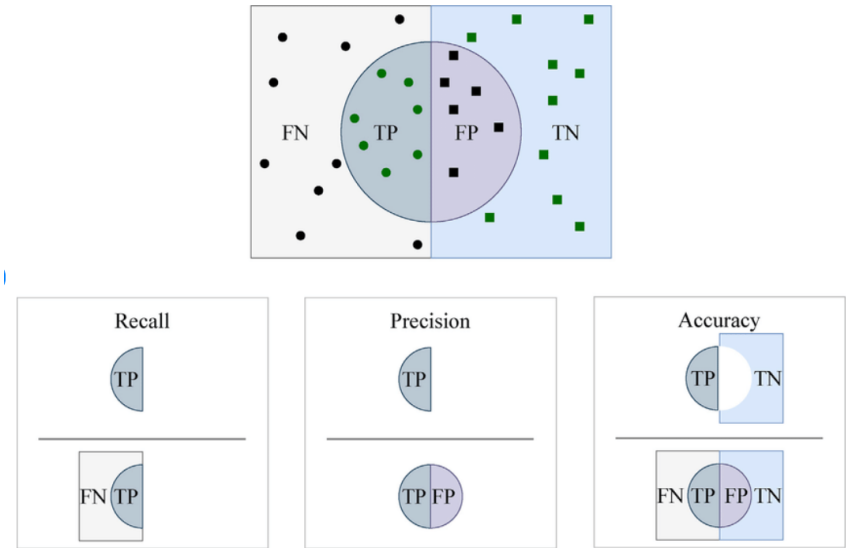

Figure 7: Precision and Recall [5]

À partir de ces quantités, plusieurs métriques classiques en classification peuvent être définies :

- **Accuracy** : proportion de prédictions correctes parmi l'ensemble des observations.

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN}. \tag{2}$$

- **Precision** (Positive Predictive Value) : fraction des observations prédites positives qui sont réellement positives.

$$\text{Precision} = \frac{TP}{TP + FP}. \tag{3}$$

- **Recall** (Sensitivity) : fraction des observations réellement positives correctement identifiées.

$$\text{Recall} = \frac{TP}{TP + FN}. \tag{4}$$

4.3 ROC Curve and AUC Metric

Dans le cadre de la classification binaire, une autre métrique très utilisée est la courbe ROC (*Receiver Operating Characteristic*) ainsi que son indicateur associé, l'AUC (*Area Under the Curve*).

La courbe ROC illustre le compromis entre le **True Positive Rate (TPR)** et le **False Positive Rate (FPR)** en faisant varier le seuil de décision du classifieur.

Le TPR (Recall) est défini par :

$$\text{TPR} = \frac{TP}{TP + FN}, \tag{5}$$

tandis que le FPR est :

$$\text{FPR} = \frac{FP}{FP + TN}. \tag{6}$$

Un classifieur performant produira une courbe ROC qui se rapproche du coin supérieur gauche, indiquant un TPR élevé et un FPR faible. À l'inverse, un modèle ne faisant pas mieux que le hasard produira une courbe proche de la diagonale, c'est-à-dire lorsque TPR = FPR.

L'AUC fournit un résumé scalaire de la performance du modèle sur l'ensemble des seuils possibles. Sa valeur est comprise entre 0 et 1 :

- AUC = 1 : perfect classifier.
- AUC = 0.5 : random classifier.
- AUC < 0.5 : worse than random, suggesting reversed decision boundaries.

Mathématiquement, l'AUC peut être interprété comme la probabilité qu'une instance positive choisie au hasard soit classée plus haut qu'une instance négative choisie au hasard.

Cette propriété rend l'AUC particulièrement pertinent dans les contextes de classes déséquilibrées, comme la prédiction du défaut de paiement sur cartes de crédit.

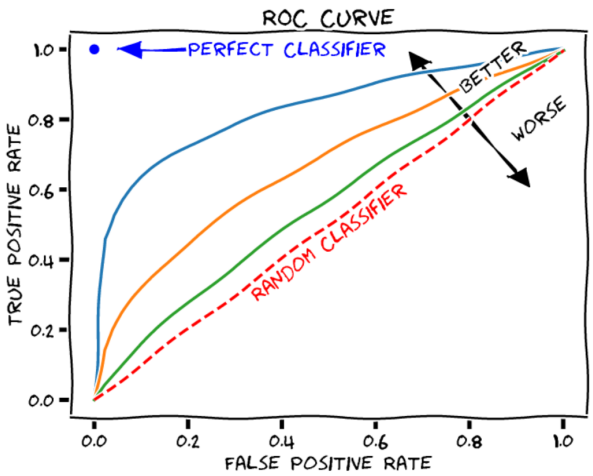

Figure 8: Example ROC curve illustrating TPR–FPR trade-off across thresholds. [6]

5 Modèles de classification

Dans cette section, nous présentons différents algorithmes d'apprentissage supervisé ainsi que leurs fondements mathématiques. Nous les appliquons ensuite à notre jeu de données afin de construire un modèle capable de prédire les défauts de paiement sur carte de crédit pour le mois suivant. Nous nous intéressons plus particulièrement aux méthodes fondées sur les arbres de décision.

5.1 Arbre de décision et Random Forest

Les méthodes basées sur les arbres offrent un mécanisme simple, intuitif et puissant pour la régression comme pour la classification. Le principe consiste à diviser un espace de caractéristiques potentiellement complexe en régions plus petites et à ajuster une fonction de prédiction simple dans chacune de ces régions [8]. Pour classer une nouvelle observation, on utilise généralement la valeur modale des observations d'entraînement appartenant à la même région.

Comme l'ensemble des règles de partition peut être représenté sous la forme d'un arbre, ces approches sont connues sous le nom de méthodes d'arbres de décision [8].

5.1.1 Arbre de décision

Les classifieurs fondés sur les arbres de décision sont particulièrement intéressants lorsque l'on souhaite préserver l'interprétabilité du modèle. Ils reposent sur la création de divisions binaires successives des variables explicatives, afin de construire un arbre permettant de classer de nouvelles observations dans l'un des deux groupes [9].

L'algorithme procède en commençant à la racine de l'arbre et en divisant les données selon la variable qui maximise le *gain d'information* (Information Gain, IG) :

- si la variable prédictive est continue, on choisit un seuil (*cut-point*) qui maximise la pureté des deux groupes formés ;
- si la variable est catégorielle, on combine les catégories afin de former deux groupes présentant une pureté maximale.

Ce processus de division est ensuite répété de manière itérative à chaque nœud enfant jusqu'à obtenir des feuilles pures, c'est-à-dire des nœuds dont toutes les observations appartiennent à la même classe. Cependant, ce processus conduit souvent à des arbres trop profonds et donc au surapprentissage. On procède alors généralement à une procédure d'élagage (*pruning*) consistant à fixer une profondeur maximale pour l'arbre.

Les critères de séparation les plus couramment utilisés dans les arbres binaires sont l'impureté de Gini (I_G) et l'entropie (I_H). En notant $p(i|t)$ la proportion d'exemples appartenant à la classe i dans un nœud t, ces critères s'écrivent :

- **Gini Impurity** : $I_G(t) = \sum_{i=1}^{c} p(i|t)(1 - p(i|t))$
- **Entropy** : $I_H(t) = -\sum_{i=1}^{c} p(i|t) \log_2 p(i|t)$

Bien qu'un arbre de décision soit interprétable, il est souvent moins précis et moins robuste que des méthodes plus avancées.

Un algorithme d'arbres plus performant est le *Random Forest*.

5.1.2 Random Forest

Le Random Forest est une méthode d'ensemble (*ensemble method*) dont le principe est de réduire la variance d'un modèle unique en combinant plusieurs arbres de décision construits selon la technique du *bagging*. Le bagging, ou *bootstrap aggregating*, consiste à générer différents ensembles d'entraînement bootstrapés, obtenus en échantillonnant avec remise à partir du jeu de données initial. La Figure 20 illustre ce principe.

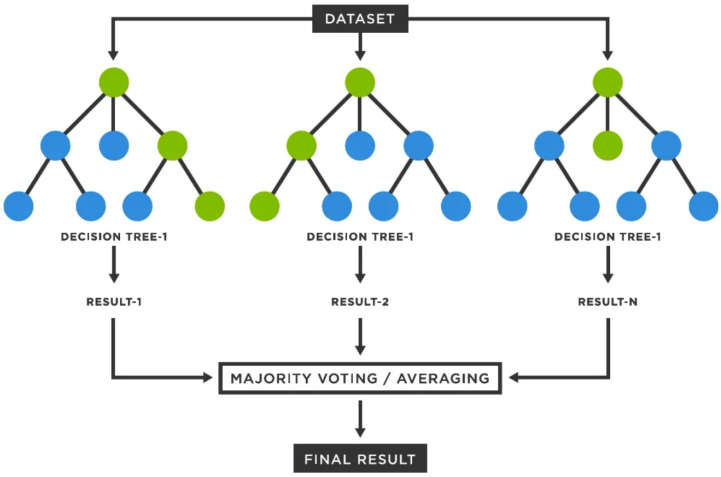

Figure 9: Random Forest [9]

Random Forest uses the bagging also at each split for the feature selection to decorrelate the trees: to generate each splitting rule it is considered a randomly selected subset of features of fixed size.

C'est pour cette raison que cet algorithme est particulièrement robuste au bruit et aux valeurs aberrantes, et qu'il présente une variance nettement plus faible qu'un arbre de décision unique. Les modèles de Random Forest ne sont pas aussi interprétables que les arbres de décision, mais ils permettent d'estimer l'importance de chaque variable explicative.

Comme nous le verrons dans la section des résultats et dans la Figure 21, l'analyse des données brutes montre que le statut de remboursement, l'âge et les montants facturés figurent parmi les variables les plus déterminantes dans le processus de décision.

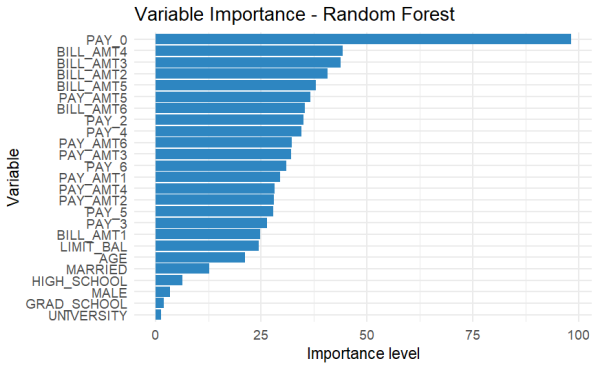

Figure 10: Feature importance obtained training Random Fores

6 Résultats

Dans les pages suivantes, nous présentons une analyse détaillée des résultats obtenus pour chacun des modèles de classification. L'objectif est d'évaluer leurs performances prédictives, de comparer leurs forces et leurs limites, et d'identifier l'approche la plus adaptée à la prédiction du défaut de paiement sur carte de crédit.

Pour chaque classifieur, nous rapportons les principales métriques de performance (Accuracy, Precision, Recall et AUC), ainsi que les matrices de confusion et les représentations graphiques associées. Ces éléments permettent d'évaluer non seulement la capacité globale de classification de chaque modèle, mais également leur efficacité à détecter les clients défaillants — un aspect essentiel dans un contexte de classes déséquilibrées.

Une discussion comparative est ensuite proposée afin de mettre en évidence les performances relatives des modèles, en insistant sur leur robustesse, leur interprétabilité et leur pouvoir prédictif. Enfin, nous dégageons les enseignements majeurs issus de l'analyse empirique et discutons leurs implications pour l'évaluation du risque de crédit.

6.1 Decision Tree

L'arbre de décision présente des performances globalement satisfaisantes, avec une **accuracy de 82.8%** indiquant une capacité correcte de classification. La **precision de 63.9%** témoigne d'une proportion raisonnable de prédictions de défaut correctement identifiées, tandis que la **recall de 37.3%** révèle une détection partielle des observations réellement défaillantes. L'**AUC de 0.76** confirme une capacité discriminante appropriée dans la séparation des bons et des mauvais payeurs. Au-delà des performances numériques, l'arbre de décision conserve l'avantage d'une **interprétabilité élevée**, permettant d'identifier aisément les variables déterminantes du comportement de paiement et d'offrir ainsi un support analytique pertinent pour l'évaluation du risque.

	Accuracy	Precision	Recall	AUC
Decision Tree	0.8201	0.6836	0.3214	0.7325

Table 2: Performance metrics of the Decision Tree model.

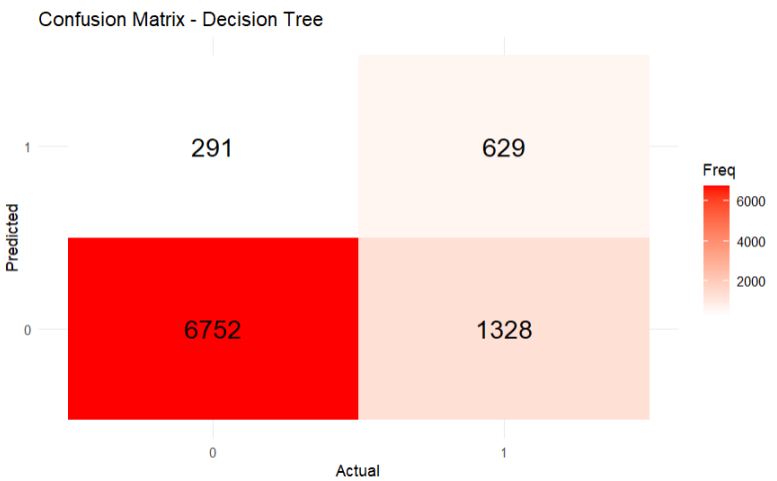

Figure 11: Confusion matrices for Decision Tree.

6.2 Random forest

Le Random Forest obtient une **accuracy de 81.8%**, comparable à celle de l'arbre de décision. Sa **precision de 63.9%** indique qu'une proportion notable des prédictions de défaut est correcte, tandis que la **recall de 37.3%** montre une détection légèrement meilleure des clients réellement défaillants. L'**AUC de 0.76** confirme une capacité discriminante correcte entre bons et mauvais payeurs. Dans l'ensemble, le Random Forest présente un comportement plus stable et plus équilibré que l'arbre de décision, tout en conservant un niveau de précision raisonnable pour l'évaluation du risque.

	Accuracy	Precision	Recall	AUC
Random Forest	0.8179	0.6392	0.3730	0.7609

Table 3: Performance metrics of the Random Forest model.

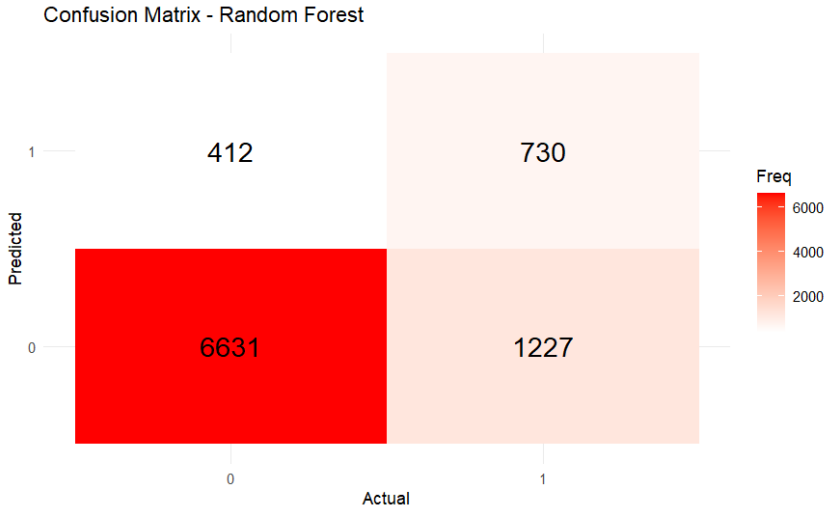

Figure 12: Confusion matrices for Random Forest model

6.3 Overall overview

Les deux modèles présentent une **accuracy comparable**, de l'ordre de 82%, indiquant une capacité similaire à classer correctement la majorité des clients. Néanmoins, le Random Forest se démarque par une **meilleure détection des observations défaillantes**, avec une recall supérieure (37% contre 32% pour l'arbre de décision). Bien que l'arbre de décision affiche une precision légèrement plus élevée, l'écart demeure limité et ne modifie pas la tendance générale.

L'**AUC**, plus élevée pour le Random Forest (0.761 contre 0.733), confirme une **capacité discriminante plus robuste** dans la séparation des bons et des mauvais payeurs.

Dans l'ensemble, même si leurs performances sont proches, le Random Forest apparaît comme le modèle le plus équilibré et le plus performant pour l'évaluation du risque, grâce à une meilleure capacité de détection et une qualité de classification globalement supérieure.

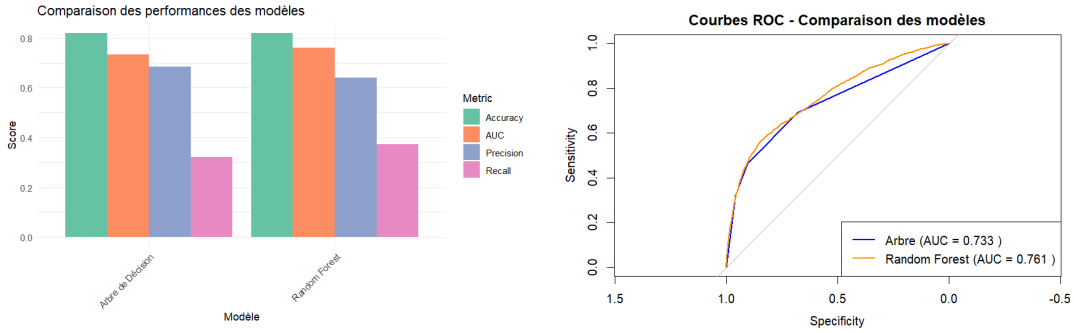

Figure 13: Comparaison entre les deux modeles

7 Conclusion

Conclusion générale

Cette étude a démontré la pertinence des méthodes d'apprentissage supervisé pour l'évaluation du risque de défaut des détenteurs de cartes de crédit. Les analyses menées indiquent que les comportements financiers récents, notamment les retards de paiement et l'évolution des montants facturés, constituent les déterminants les plus fiables du défaut, tandis que les variables démographiques jouent un rôle nettement secondaire. Parmi les modèles testés, le Random Forest se distingue par une performance plus stable et une meilleure capacité discriminante, ce qui en fait un outil particulièrement adapté aux applications opérationnelles en gestion du risque. L'ensemble des résultats met en lumière la capacité des approches quantitatives à offrir une lecture objective et prédictive du phénomène de défaut, dans un contexte où la maîtrise du risque de crédit demeure un enjeu stratégique pour les institutions financières.

Bibliography

[1] Dua, D., & Graff, C. (2019). UCI Machine Learning Repository: Default of credit card clients data set. link

[2] Yeh, I.-C., & Lien, C.-H. (2009). The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. *Expert Systems with Applications*, 36(2), 2473–2480. link

[3] Alam, T. M., Shaukat, K., Hameed, I. A., Luo, S., Sarwar, M. U., Shabbir, S., Li, J., & Khushi, M. (2020). An investigation of credit card default prediction in the imbalanced datasets. *IEEE Access*, 8, 201173–201198. link

[4] Rosaen, K. (2016). Machine Learning Log Image. link

[5] Overview of Machine Learning Part 1 (2020). link

[6] Serengil, S. I. (2020). A Gentle Introduction to ROC Curve and AUC. link

[7] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning with Applications in R*. Springer Texts in Statistics, Vol. 103, Springer.

[8] Kabacoff, R. I. (2015). *R in Action* (2nd ed.). Manning Publications. link

[9] Günay, D. (2020). Random Forest. link

[10] Fischer, A. (2024). *Cours d'Apprentissage Statistique*. Master 2 ISIFAR, Université Paris Cité.

[11] Understanding Machine Learning: From Theory to Algorithms, S. Shalev-Shwartz, S. Ben-David, 2014. link